

基于专家用户的可信推荐系统

王宁 徐锋

(南京大学计算机软件新技术国家重点实验室 南京 210093)

(南京大学计算机软件研究所 南京 210093)

摘要 随着互联网的迅速发展,信息出现了爆炸式增长。推荐系统作为信息过滤的重要手段,是解决信息过载问题的有效方法。如何给缺少评分信息和信任关系的新用户提供有效的推荐信息,是推荐系统面临的一个重要问题。基于协同过滤的推荐系统和基于信任的推荐系统均无法很好地解决这一问题。提出了一个基于专家用户的可信推荐模型,即在信任网络中发掘出专家用户,然后利用这些专家用户来扩展新用户的信任网络,从而为新用户提供有效的推荐信息。在 Epinions 数据集上的实验结果表明,该方法提高了推荐系统的正确率和覆盖率,有效地解决了新用户问题。

关键词 推荐系统,信任网络,新用户

中图分类号 TP301 文献标识码 A

Trust-aware Recommender System Based on Expert User

WANG Ning XU Feng

(State Key Laboratory for Novel Software Technology, Nanjing University, Nanjing 210093, China)

(Institute of Computer Software, Nanjing University, Nanjing 210093, China)

Abstract With the rapid development of Internet, there has been explosive growth of information. As an important means of information filtering, recommender system is an effective way to solve the information overloading problem. How to provide effective information to new users who are lack of rating information and trust relationship, is an important issue that recommender system faces. In this paper, we propose a trust-aware recommender system based on expert users. We use expert users which are discovered through trust network to extend new user's trust network, so it is able to provide new users useful information. An empirical evaluation on Epinions.com dataset shows that trust-aware recommender system based on expert user has higher recommend accuracy and coverage, especially for cold-start users.

Keywords Recommender system, Trust network, Cold start

1 引言

随着互联网规模和覆盖面的迅速扩大,充斥在网络中的资源也呈指数级的爆炸式增长。用户面对海量的信息,往往无所适从,很难从中寻找出适合自己的信息,这就是所谓的信息过载问题。推荐系统作为一种信息过滤的重要手段,是当前解决信息过载问题的一个比较有效的方法。它根据用户的偏好特性,从大量的信息中挖掘出用户最可能感兴趣或

需要的信息,并推荐给用户。

常见的推荐系统方法是协同过滤方法^[1],其基本思想是找出与目标用户口味或兴趣相似的用户,并将相似邻居用户感兴趣的信息推荐给目标用户。这是推荐系统中一种比较成功的方法。然而,协同过滤方法仍然有一些问题,其中最重要的一个弱点就是新用户问题(cold start problem):新用户由于评价的信息过少,导致无法找到与其相似的用户,从而很难给出适合的推荐信息。随着社会网络的出现

本文受国家自然科学基金(60735015, 60721002, 61073030), 国家 973 计划(2009CB320702), 国家 863 计划(2009AA01Z117), 江苏省攀登计划(BK2008017)资助。

王宁(1987-),男,硕士生,主要研究方向为可信计算等, E-mail: ephram1987@gmail.com; 徐锋 男,博士,教授,主要研究方向为可信计算、系统安全、软件可靠性技术等。

和流行,研究者发现用户倾向于喜欢朋友推荐的信息^[2]。用户在社会网络中会结识一些朋友,这可以被作为推荐信息的一个可靠的来源。日常生活中,人们需要建议的时候,往往会去向那些他们信任的人寻求帮助。因此,研究者们将信任网络引入推荐系统,提出了具有可信机制的推荐系统^[3-6]。引入信任网络到推荐系统,用户只需要加入到信任网络中来,通过信任的传播和聚合,可以得到更多的推荐信息,因而在一定程度上减少了协同过滤方法中的新用户问题。然而要获得推荐信息,用户必须尽快地加入到信任网络中来,而大多数新用户在社会网络中,往往是孤立的节点,这样就很难给这些用户提供适合的推荐信息,所以基于信任的方法也没有很好地解决新用户问题。

针对现有的方法都不能很好地解决新用户问题,本文提出了一个基于专家用户的可信推荐模型,即在信任网络中发掘出专家用户,然后利用这些专家用户来扩展新用户的信任网络,从而能够给新用户提供有效的推荐信息。在 *epinions*^[7] 的数据集上进行了实验,结果表明该方法能有效解决新用户问题。

本文第2节介绍相关工作;第3节介绍基于专家用户的可信推荐系统模型;第4节是实验与分析;最后是总结与展望。

2 相关工作

推荐系统主要分为两大类,一类是传统的基于协同过滤方法的推荐系统,另一类是最近流行的基于信任的推荐系统。两类方法在解决新用户的推荐问题时均存在不足。

2.1 传统的协同过滤方法

Goldberg 等人^[8]提出的协同过滤推荐方法是推荐系统中最为成功的技术之一。大量的电子商务网站,如 *amazon* 等,都采用这个技术。协同过滤方法的基本思想非常易于理解:兴趣或者口味与我们相似的用户喜欢的东西往往也是我们喜欢的。协同过滤方法从用户的评价信息出发,寻找与当前用户兴趣偏好相似的用户群,根据这些用户的喜好来进行推荐。

协同过滤算法分两个步骤。第一步是相似度计算,根据个用户的评分值(矩阵中的每行)分别计算他们的相似度。最常见的相似度计算方法有 Pearson 相关系数。第二步是评分预测:根据最相似的用户集的评分信息进行推荐。预测的评分是最相似用户集中各用户评分的加权平均,其中的权值就是

与目标用户的相似度,这样的话相似度大的用户会有较大的影响值。目标用户 a 对项目 j 的预测评分的计算公式如下:

$$p_{a,j} = \bar{r}_a + \frac{\sum_{u=1}^k \text{sim}(a,u) * (r_{u,j} - \bar{r}_u)}{\sum_{u=1}^k \text{sim}(a,u)} \quad (1)$$

式中, $p_{a,j}$ 表示用户 a 对项目 j 的预测评分, \bar{r}_a 和 \bar{r}_u 分别是用户 a 和用户 u 的平均评分, $\text{sim}(a,u)$ 是前面计算的用户 a 与用户 u 的相似度, k 是用户的邻居数。

根据式(1),一个用户只要能计算出与目标用户的相似值,那就是目标用户的邻居,能对用户产生推荐。这样的话第一步的相似值计算就显得尤为重要。由于系统中的项目数会比较大,而一般用户只会评价其中很小的一部分,这就会使得用户-项目评分矩阵非常稀疏,从而影响推荐的准确率。

在新用户的推荐上,协同过滤方法的缺点更加明显。新用户是指那些刚开始使用推荐系统、没有给出评分或者给出的评分数很少的用户。对于这些用户,协同过滤方法无法给他们找出邻居,从而无法给出推荐信息。

2.2 基于信任的方法

传统的基于协同过滤方法的推荐系统认为所有用户都是独立的,忽视了用户之间的社会性质。实际生活当中,当目标用户需要了解某个项目的信息的时候,他们往往会去向其信任的朋友去咨询。因此,许多研究者提出了基于信任网络的推荐系统^[3-6]。

基于信任的方法额外使用了信任网络中用户之间的信任与不信任关系,因而能够减轻新用户问题。信任网络可以通过用户评分的相似性自动生成^[9],或者让用户显式地给出对其他用户的信任值^[10,11]。Massa and Avesani 在文献[5,6]中研究了基于信任的推荐系统,他们提出了信任网络中的信任传递算法,用信任值替代了协同过滤方法中的相似值计算。在大规模真实数据集 *epinions* 上的实验表明,相比协同过滤方法,基于信任的方法在没有降低推荐正确率的前提下提高了推荐的覆盖率^[13]。

随着社会网络的兴起与发展,大量的人成为了社交网络中的一员,其中大部分网络都有信任关系。将用户接入信任网络,可以极大改善对其的推荐质量。然而,推荐系统中的新用户,在信任网络中往往是孤立的节点或者只有很少的信任关系。怎样将这类新用户更好地加入信任网络,是解决推荐系统中新用户问题的关键。本文提出了一个基于专家用户

的可信推荐模型,即在信任网络中发掘出专家用户,然后利用这些专家用户来扩展新用户的信任网络,从而为新用户提供有效的推荐信息。

3 基于专家用户的可信推荐系统

推荐系统中的实体分为两类:用户和物品。令 $U = \{u_1, u_2, \dots, u_M\}$, 表示用户的集合, $I = \{i_1, i_2, \dots, i_N\}$, 表示物品的集合。每个用户 $u (u \in U)$ 评价了 K 个物品 ($K < N$), 即 $R_u^I = \{R_u^1, R_u^2, \dots, R_u^K\}$, 其中 R_u^I 是用户 U 对物品 I 的评分。同时, 用户又存在于一个社会网络中, 我们用 T_u 表示用户 u 对用户 v 的信任值 ($u, v \in U$)。推荐系统怎样给用户推荐物品, 有 3 个步骤: 首先找出目标用户的推荐者集合, 然后计算目标用户对各推荐者的信任值, 最后综合推荐者对目标物品的评分来预测目标用户对目标物品的评分, 选出预测评分较高的物品来推荐给目标用户。

推荐系统中的新用户, 往往在信任网络中是孤立的节点。这些刚加入推荐系统的新用户并不知道他们应该信任哪些用户的推荐, 因而无所适从。我们认为, 专家用户的建议比普通用户的建议更加可靠, 利用专家用户的建议, 可以给出更好的推荐信息。在基于专家用户的可信推荐系统中, 通过专家评估算法, 从信任网络中发掘出一些专家用户, 利用这些专家用户来扩展新用户的信任网络, 如图 1 所示。




图 1 基于专家用户的可信推荐系统

我们首先介绍专家用户评估模型, 利用选出的专家用户来扩展新用户的推荐者集合, 然后介绍综合信任度与相似度的信任计算模型, 最后给出用户评分预测公式。

3.1 专家用户评估模型

在现实生活中, 每个人都有其擅长的地方, 因此, 每个领域都会存在一批专家。人们想获得信息时, 常常会希望得到专家的信息。同样, 在推荐系统

中, 也会有一些专家用户, 他们对部分物品比较了解, 并给出了较多公正的评价。本文定义的专家用户是这样一群: 他们对大量的资源有自己的看法, 并且他们的看法被大多数人认同, 同时他们在信任网络中也具有较高的信任值。因此, 我们用以下公式来评估用户的专业性:

$$Eval(u) = f(F(u), E(u), R(u)) \quad (2)$$

式中, $F(u)$ 表示用户的活跃度, $E(u)$ 表示用户的专业性, $R(u)$ 表示用户的声誉值。

3.1.1 活跃度

专家用户与一般用户的区别在于专家用户会有一些擅长的方面, 因此会给出更多的评价。用户评价的物品越多, 则他的活跃性越高。用 N_{\max} 来表示推荐系统中评价物品最多的用户的评价次数, 则用户在推荐系统中的活跃度可以由以下公式计算, 其中 N_u 表示用户 u 的评价次数:

$$F(u) = \frac{N_u}{N_{\max}} \quad (3)$$

3.1.2 专业性

专家用户必须具有较高的专业性, 即他们的评分都应该比较准确, 与物品的平均评分相差不大。如果物品 i 被 N 个用户评分过, 那么物品 i 的平均评分就是:

$$\bar{R}^i = \frac{1}{N} * \sum_{u=1}^N R_u^i \quad (4)$$

为了避免评分用户过少, 以致当前用户的打分影响较大, 我们要去掉当前用户的打分的影响, 于是我们用下面的公式计算平均评分:

$$\bar{R}^i = \frac{1}{N-1} * (\sum_{u=1}^N R_u^i) - R_u^i \quad (5)$$

则用户对每件商品评分偏差归一化后如下, 其中 R_{\max} 是评分最大值:

$$V(R_u^i) = 1 - \frac{|R_u^i - \bar{R}^i|}{R_{\max}} \quad (6)$$

最后我们用用户评分的偏差的平均值来表示用户的专业性, 如式(8), 其中 M 是用户给出的评价次数:

$$E(u) = \frac{1}{M} \sum_{i=1}^M V(R_u^i) = \frac{1}{M} \sum_{i=1}^M (1 - \frac{|R_u^i - \bar{R}^i|}{R_{\max}}) \quad (7)$$

3.1.3 声誉值

专家用户在社会网络中必须具有较高的声誉值, 即他们在社会网络中有比较多的信任他们的用户。用用户的直接信任者数量与有最多信任者用户的信任者的数量的比值来表示用户的信任度:

$$R(u) = \frac{M_u}{M_{\max}} \quad (8)$$

式中, M_u 是信任用户 u 的用户个数, M_{\max} 是拥有最

多信任者的用户的信任者的数量。

3.1.4 评估专家

通过综合活跃度、专业性、信任度,用下面的公式来评估专家:

$$Eval(u) = \alpha * F(u) + \beta * E(u) + \gamma * R(u) \quad (9)$$

式中, $\alpha + \beta + \gamma = 1$, 分别表示各部分的权重。

3.2 利用专家用户扩展信任网络

根据专家评估公式,若 $Eval(u) > Eval(threshold)$, ($Eval(threshold)$ 是调节专家数量的阈值), 我们便认为用户 u 是专家用户。 $E = \{u | u \in U, Eval(u) > Eval(threshold)\}$ 是专家用户的集合。因此,对推荐系统中的新用户 v , 令 $T_v^u = 1 (u \in E)$, 则新用户的信任网络就得到了扩展。

3.3 信任计算模型

在计算用户间的信任值时,我们不仅仅考虑用户在社会网络中的信任值,同时还要考虑用户之间口味的相似度。为了解决新用户问题,我们将专家用户加入到新用户的信任网络,但是各个领域的专家用户不可能都与目标用户的口味一致。因此,引入用户相似度作为信任度的一个补充,综合考虑社会网络中的信任度和用户口味的相似度,可以更精确地找到目标用户的最近邻居集合,从而提高推荐系统的效果。信任计算模型如图2所示。




图2 信任计算模型

3.3.1 信任值的传递

通常认为社会网络中的信任具有传递性,如 A 信任 B , B 信任 C , 则可以得出 A 也信任 C , 同时信任在传递的过程中会衰减。在本文的推荐系统模型中,设定信任传递的最大跳数为 d , 推荐者与目标用户之间的距离为 n , 则目标用户对推荐者的信任度可以由以下信任衰减公式计算:

$$T_{xial}(i, j) = \frac{d-n+1}{d} \quad (10)$$

3.3.2 相似值的计算

本文采用 Pearson 相关系数来计算用户间的相似性。计算 Pearson 相关系数时,首先要找出两个用户所共同评价过的物品的集合,记为 U , 则用户 i

与用户 j 之间的相似度由以下公式计算:

$$T_{sim}(i, j) = \frac{\sum_{x \in U} (r_{i,x} - \bar{r}_i)(r_{j,x} - \bar{r}_j)}{\sqrt{\sum_{x \in U} (r_{i,x} - \bar{r}_i)^2 \sum_{x \in U} (r_{j,x} - \bar{r}_j)^2}} \quad (11)$$

Pearson 相关系数分布在 $[-1, 1]$ 区间, -1 表示 a 和 b 之间最不相似, 1 表示 i 和 j 之间最相似。在实际应用中,小于 0 的相似度不具备参考意义,因此我们只考虑相似度大于 0 的情况。当两个用户共同评价的物品数量小于 2 时, Pearson 相关系数也没有意义。

3.3.3 综合信任值的计算

用户之间的综合信任值通过信任值与相似值的加权平均来计算,计算公式如下:

$$T_{sur}(i, j) = \alpha * T_{xial}(i, j) + \beta * T_{sim}(i, j) \quad (12)$$

式中, $\alpha + \beta = 1$ 。

3.4 用户评分估计

根据上述公式,选出可信的用户作为目标用户的推荐者,采用 Resnick 公式^[1]的变种来计算目标用户对未知项目的预测评分:

$$R_{u,i} = \bar{R}_u + \frac{\sum_v Trust_{u,v} * (R_{v,i} - \bar{R}_v)}{\sum_v Trust_{u,v}} \quad (13)$$

式中, \bar{R}_u 是用户 u 对项目的平均评分。选择预测评分最高且目标用户未评分的 N 个项目推荐给目标用户,推荐过程完成。

4 实验

我们先介绍了实验使用的数据集和推荐系统的评估标准与方法,然后对实验结果进行了分析与总结。

4.1 实验数据集

实验采用的数据集^[12]来自于一个著名的电子商务商品评价网站 Epinions.com。在 Epinions 网站上,用户可以对不同类别的物品(例如书、电影、音乐、汽车等)进行评分。数据集中包括 40290 个用户对 139738 个商品项目的 664824 条商品的评分数据,除此之外,还有关于用户之间的 487181 条信任关系评分数据。用户对物品的评分范围为从 1 到 5 , 1 表示最低的评分值, 5 表示最高的评分值。用户之间的信任关系评分为 1 或者为空, 1 表示评分用户信任被评用户,空值表示用户之间没有信任评分。这个数据集的评分矩阵的稀疏度为 99.99135% 。用户的平均评分次数为 13.49 , 标准差为 34.16 , 在这个数据集中,有 26037 个用户评分的次数小于 5 , 占了总用户的 52.82% , 由此可见,这个系统中有大量的新用户存在。

4.2 评估标准和方法

本文采用的评估方法是机器学习中常见的

leave-one-out 方法。先将已有的评分隐藏起来,然后利用推荐系统对该评分进行预测。根据预测评分与真实评分的差距来对推荐系统进行评估。

推荐系统的性能指标一般有推荐的准确度和推荐的覆盖率两个方面^[13],使用的指标有平均绝对误差 MAE (Mean Absolute Error) 和覆盖率 (Coverage)。平均绝对误差 MAE 通过计算预测的用户评分与实际的评分之间的误差度量来评价评分预测的准确性。假设 P_i 表示测试用户对测试集中第 i 项的预测评分值, q_i 表示测试用户对测试集中第 i 项的实际评分值, n 表示所有的评分数目。那么,该用户的平均绝对误差 MAE 由下面公式得到:

$$MAE = \frac{\sum_{i=1}^n |p_i - q_i|}{n} \quad (14)$$

根据上述公式,评价较多的用户会有比较大的权值,而数据集的大量评价较少的新用户只有很少的权值。为了平衡所有用户,本文还采用平均绝对用户误差 MAUE (Mean Absolute User Error) 这个标准,即对每个用户计算 MAE,然后进行平均。 m 为用户数,公式如下:


$$MAUE = \frac{\sum_{u=1}^m MAE_u}{m} \quad (15)$$

在推荐系统中,能够计算的预测评分数量也是重要的评价标准之一。一般我们用评分覆盖率和

用户覆盖率来评价这一标准。根据文献[13],评分覆盖率的定义是用户的所有评分被隐藏起来后,被推荐系统给出的预测评分的数目与所用评分数的比。在 Epinions 这样的非常稀疏的数据集中,由于存在大量新用户,对推荐系统给出预测评分带来了很大的困难,因此评分覆盖率是衡量推荐系统对新用户推荐质量的一个重要指标。除了评分覆盖率以外,还要考虑做出推荐的用户的覆盖率,用户覆盖率指给出预测评分的用户数与所用用户数的比值。在相同的物品推荐数量下,相比于向同一个用户推荐 100 件商品,向 100 个用户每人推荐 1 件商品,用户覆盖率更高,推荐的效果更好。因此本文同时采用评分覆盖率和用户覆盖率两个评价标准。

4.3 实验结果与分析

将基于专家用户的可信推荐模型与协同过滤方法、基于信任的方法在 MAE、MAUE、Rating Coverage、User Coverage 4 个方面进行了比较。本文将 Epinions 数据集中评分数小于 5 并且朋友数小于 5 的用户认为是新用户。在专家评估公式中,我们对活跃度、专业性、声誉值给出的权重分别是 $\alpha=0.4$, $\beta=0.4$, $\gamma=0.2$ 。根据实验,当专家数量大于 20 个时,覆盖率增加不明显而错误率会上升,因此我们每次选取的专家用户数量是 20。在信任计算模型中,我们给出的信任值与相似值的权重分别是 $\alpha=0.5$, $\beta=0.5$ 。实验结果如图 3 所示。



方法 1、方法 2、方法 3 分别表示协同过滤、基于信任的和基于专家用户的

图 3 实验结果

从实验结果可以看出,引入专家用户来扩展新用户的信任网络,在错误率没有上升的情况下,提高了推荐系统的覆盖率,尤其是对新用户。该方法在一定程度上解决了推荐系统的新用户问题。

结束语 为了解决现有推荐系统中的新用户问题,即新用户无法获得有效的推荐信息,本文提出了一个基于专家用户的可信推荐系统,首先通过专家评估算法在信任网络中发掘出专家用户,然后利用这些专家用户来扩展新用户的信任网络,从而给新用户提供有效的推荐信息。对于用户间信任值的计算,本文提出了综合相似度与信任度的信任计算模型,从而能够更精确地找到目标用户的最近邻居集合。在 Epinions.com 数据集上的实验表明本文的方法对解决新用户问题是有效的。

未来的工作还有以下几点:首先,改进专家选取算法,使得能够更有效地选出专家用户,例如通过机器学习等方法,动态地调整活跃度、专业性、声誉值的权重。本文的基于专家用户的可信推荐系统还没有考虑到在实际使用中的一些性能上的问题,以后的工作可以在推荐者选取和信任计算的时候做一些优化,使得该推荐系统更具实用性。

参考文献

[1] Resnick P, Iacovou N, Suchak M, et al. Grouplens, An open architecture for collaborative filtering of netnews[C]//Proc. of CSCW1994. 1994;175-186

[2] Lerman K. Social networks and social information filtering on digg. Arxiv preprint cs/0612046
[3] Andersen R, Borgs C, Chayes J, et al. Trust-based recommendation systems: an axiomatic approach[C]//Proc. of WWW'08. New York, NY, USA, ACM, 2008;199-208
[4] Bedi P, Kaur H, Marwaha S. Trust based recommender system for semantic Web[C]//Proc. of IJCAI '07. 2007;2677-2682
[5] Massa P, Avesani P. Trust-aware collaborative filtering for recommender systems[C]//Proc. of CoopIS/DOA/ODBASE. 2004;492-508
[6] Massa P, Avesani P. Trust-aware recommender systems[C]//Proc. of RecSys. New York, NY, USA, ACM, 2007;17-24
[7] <http://www.epinions.com>
[8] Goldberg D, Nichols D, Oki B M, et al. Using Collaborative Filtering to Weave an Information Tapestry[J]. Communications of the ACM, 1992, 35(12):61-70
[9] Papagelis M, Plexousakis D, Kutsuras T. Alleviating the sparsity problem of collaborative filtering using trust inferences[J]. LNCS, 2005, 3477:224-239
[10] Golbeck J, Hendler J. FilmTrust: movie recommendations using trust in web-based social networks[C]//Proc. of CCNC2006. 2006;282-286
[11] Massa P, Avesani A, Tiella R. A trust-enhanced recommender system application: Moleskiing[C]//Proc. of SAC2005. 2005;1589-1593
[12] http://www.trustlet.org/wiki/Epinions_dataset
[13] Massa P, Bhattacharjee B. Using trust in recommender systems: an experimental analysis[C]//Proc. of 2nd Int. Conference on Trust Management. 2004

(上接第 200 页)

系统结构带来的变化,为了提高系统的可靠性,极大地延长 PRAM 的使用寿命,在现有操作系统基础上提出了带有磨损均衡的伙伴系统,同时利用程序的段信息将需要频繁修改的程序段加载到 DRAM 内存区域,实现了对 PRAM 的管理。通过实验验证了我们的面向新型混合内存的物理内存管理方法是行之有效的,PRAM 中的物理内存块被均匀地分配,极大地防止了 PRAM 内存页被快速损耗,提高了系统的稳定性。通过在操作系统中支持 PRAM,可以供上层应用程序根据自身情况灵活地请求内存分配。

参考文献

[1] Ramos L E, Gorbato E, Bianchini R. Page placement in hybrid memory systems[C]//International conference on Supercomputing. 2011;85-95
[2] Zhou P, Zhao B, Yang J, et al. A durable and energy efficient main memory using phase change memory technology[C]//The 36th International Symposium on Computer Architecture. ACM, 2009;14-23
[3] Qureshi M K, Srinivasan V, Rivers J A, et al. Scalable high per-

formance main memory system using phase change memory technology[C]//The 36th International Symposium on Computer Architecture. ACM, 2009;24-33

[4] Lee B C, Ipek E, Mutlu O, et al. Architecting phase change memory as a scalable dram alternative[C]//The 36th International Symposium on Computer Architecture. ACM, 2009;2-13
[5] Qureshi M K, Karidis J, Franceschini M, et al. Enhancing lifetime and security of pcm-based main memory with start-gap wear leveling[C]//Proceedings of the 42nd Annual IEEE/ACM International Symposium on Microarchitecture. ACM, 2009;14-23
[6] McKusick M K, Neville-Neil G V. The design and implementation of the FreeBSD operating system[M]. Addison Wesley, 2002
[7] Bover D, Cesati M, Oram A. Understanding the Linux kernel [M]. O'Reilly, 2002
[8] Knuth D E. The art of computer programming, Volume 1: Fundamental Algorithms [M]. Addison Wesley, 1997;Section 2.5
[9] Binkert N L, Dreslinski R G, Hsu L R, et al. The M5 simulator: Modeling networked systems [J]. IEEE Micro, 2006, 26(4):52-60
[10] Kaashoek F, Cates J, Sit E. XV6[OL]. <http://pdos.csail.mit.edu/6.828/xv6/>